

Análise Exploratória de Dados Aimê @itsaime

Conteúdo da aula

- Análise exploratória de dados
 - Análise intuitiva através da visualização de dados
 - Análise estatística
- Limpeza de dados
- Seleção de atributos

Introdução

- É importante compreender a complexidade dos dados que estamos lidando
- Precisamos mensurar a:
 - propriedades dos dados;
 - qualidade dos dados;
 - e o poder preditivo dos dados.

```
"age"; "job"; "marital"; "education"; "default"; "balance"; "housing"; "loan'
58: "management": "married": "tertiary": "no": 2143: "yes": "no": "unknown": 5:
44; "technician"; "single"; "secondary"; "no"; 29; "yes"; "no"; "unknown"; 5; "r
33; "entrepreneur"; "married"; "secondary"; "no"; 2; "yes"; "yes"; "unknown"; 5
47; "blue-collar"; "married"; "unknown"; "no"; 1506; "yes"; "no"; "unknown"; 5;
33; "unknown"; "single"; "unknown"; "no"; "no"; "no"; "unknown"; 5; "may"; 198
35; "management"; "married"; "tertiary"; "no"; 231; "yes"; "no"; "unknown"; 5; "
28; "management"; "single"; "tertiary"; "no"; 447; "yes"; "yes"; "unknown"; 5; "
42; "entrepreneur"; "divorced"; "tertiary"; "yes"; 2; "yes"; "no"; "unknown"; 5
58; "retired"; "married"; "primary"; "no"; 121; "yes"; "no"; "unknown"; 5; "may"
43; "technician"; "single"; "secondary"; "no"; 593; "yes"; "no"; "unknown"; 5; "
41; "admin."; "divorced"; "secondary"; "no"; 270; "yes"; "no"; "unknown"; 5; "ma
29; "admin.": "single": "secondary": "no": 390; "ves": "no": "unknown": 5; "may"
53; "technician"; "married"; "secondary"; "no"; 6; "yes"; "no"; "unknown"; 5; "n
58; "technician"; "married"; "unknown"; "no"; 71; "yes"; "no"; "unknown"; 5; "ma
57; "services"; "married"; "secondary"; "no"; 162; "yes"; "no"; "unknown"; 5; "n
51. "notined": "mannied": "noimany": "no": 330. "yes": "no": "unknown": 5. "may!"
```

Análise estatística de dados

Esse passo é usado para qualquer dataset, não só os usados para ML. Iremos avaliar a qualidade e o poder preditivo dos dados.

Conteúdo:

- Análise univariada (descritiva)
- Análise bivariada (correlação)
 - Qualitativa
 - Quantitativa
- Análise contextual

Análise univariada (descritiva)

Atributo comum

- **Tipo do dado** (importante!!!)
- Valores faltantes (printar tabela com porcentagem de cada coluna)

Atributo categórico

- cardinalidade (baixa == muitos elementos duplicados)
- quantidade de valores únicos

Atributo numérico

- Quantis estatísticos (Q1, Q2, Q3, min, max, range)
- Estatística descritiva (mean, mode, sd, median, kurtosis, skewness)
- Histograma de distribuição

Atributo textual

- tokens
- document frequency (DF)/ term frequency
 (TF) sem palavras vazias (stop words)

Passo crucial.

Verificar atributos comuns: valores faltantes e tipo de dado das colunas.

ı	Missing Values	Percentage	Data Types
ld	0	0.000000	int64
MSSubClass	0	0.000000	int64
MSZoning	0	0.000000	object
LotFrontage	259	17.739726	float64
LotArea	0	0.000000	int64

MoSold	0	0.000000	int64
YrSold	0	0.000000	int64
SaleType	0	0.000000	object
SaleCondition	0	0.000000	object
SalePrice	0	0.000000	int64

Limpeza dos dados


- Remover duplicados
- Remover dados irrelevantes
- Padronizar capitalização
- Converter tipos de dado
- Remover erros e inconsistências
- Todos dados na mesma linguagem
- Lidar com dados faltantes
- Lidar com outliers

Atributos numéricos


	max	range	IQR	mode	mad	kurtosis	skewness
age	90	73	20	36	11.189182	-0.166127	0.558743
functional_weight	1484705	1472420	119224	123011	77608.21854	6.218811	1.44698
education_num	16	15	3	9	1.903048	0.623444	-0.311676
capital_gain	99999	99999	0	0	1977.373437	154.799438	11.953848
capital_loss	4356	4356	0	0	166.462055	20.376802	4.594629
hours_per_week	99	98	5	40	7.583228	2.916687	0.227643

	mean	std	min	25%	50%	75%
age	38.581647	13.640433	17	28	37	48
functional_weight	189778.3665	105549.9777	12285	117827	178356	237051
education_num	10.080679	2.57272	1	9	10	12
capital_gain	1077.648844	7385.292085	0	0	0	0
capital_loss	87.30383	402.960219	0	0	0	0
hours_per_week	40.437456	12.347429	1	40	40	45

Mixture of Gaussians - bimodal



Podem ser representados por gráficos






Figure 1. Common Components of Box Plot and Violin Plot. Total compensation for all academic ranks.

Plot de histograma, densidade, boxplot e violino.

Análise bivariada (de correlação)

Examina correlação entre variáveis, dois a dois. Determina variáveis redundantes e/ou que não são preditivas em relação ao valor alvo.

Qualitativa:

- 2 categóricas: tabela de contingência
- categórica vs. numérica: estatística descritiva ou histograma

Problemas: enviesamento (verificado com métodos de amostragem e design de experimentos)

Quantitativa:

Teste de Hipóteses, onde a hipótese nula é de que não há relação entre as duas variáveis. Usamos p-valor de 0.05.

Tabela de contingência

Item	Extra				
Pizza	Cheese				
Pizza	Sauce			Cheese	Sauce
101410000		\longrightarrow	Pizza	1	1
Burger	Cheese		Burger	2	1
Burger	Cheese				
GIACIE MACCONE	7 /2000 10 1				

Sauce

Handed- ness Sex	Right-handed	Left-handed	Total
Male	43	9	52
Female	44	4	48
Total	87	13	100

Teste de hipóteses

v		Y
X	Categorical	Numerical
Categorical	Chi-square test Information gain	Student T-test ANOVA Logistic regression Discretize Y (left column)
Numerical	Student T-test ANOVA Logistic regression Discretize X (row above)	Correlation Linear Regression Discretize Y (left column) Discretize X (row above)

Handedness	Diabet banded	Left-handed	Total
Sex	Right-handed	Lett-nanded	Total
Male	43	9	52
Female	44	4	48
Total	87	13	100

Right-handed	Left-handed	Total
100*0.52*0.87=45	100*0.52*0.13=7	52
100*0.48*0.87=42	100*0.48*0.13=6	48
87	13	100
	100*0.48*0.87=42	100*0.52*0.87=45 100*0.52*0.13=7 100*0.48*0.87=42 100*0.48*0.13=6

Test the statistics.

$$\chi^{2} = \sum_{i=1}^{r} \sum_{j=1}^{c} \frac{(O_{ij} - E_{ij})^{2}}{E_{ij}} = \frac{(43 - 45)^{2}}{45} + \frac{(44 - 42)^{2}}{42} + \frac{(9 - 7)^{2}}{7} + \frac{(4 - 6)^{2}}{6} = 1.42$$

$$p_{value} = P r_{DF=1} (\chi^{2} > 1.42) = 0.233$$

Exemplo de Teste Chi-Quadrado

Análise Contextual

Entender o contexto no qual o dataset está inserido pode nos dar insights em relação aos dados.

Baseada em tempo:

- horas de rush
- quebra da bolsa de 2008
- datas de eleição
- black friday


Baseado em usuários.

- verificar comportamento de cada usuário ou em conjunto
- achar anomalias

Seleção de atributos

Baseado em:

- Análise descritiva
- Análise de correlação
- Análise contextual



Seleção de atributos

Baseado em análise descritiva

- Alta porcentagem de números faltantes não constituindo informação
- Pouca variância. Remover esses dados pode diminuir complexidade da ML
- Pouca entropia de categorias pode enviesar
 ML
 - Desbalanço de classe pode ser resolvida com amostragem
- Distribuição distorcida com calda longa.
 Pode ser resultado de erros que geram outliers.
- Alta cardinalidade, ou seja, muitos valores únicos

Baseado em análise de correlação

- Correlação muito baixa pode significar que atributo não será útil para previsão desejada
- Alta correlação. Não acrescenta informação ao modelo e não é recomendada para modelos lineares.

Baseado em análise contextual

Leva em conta conhecimento do contexto em que os dados estão inseridos.

Visualização de dados

Tabelas

Guiar o leitor para a informação que queremos passar. Procurar não usar bordas, pois poluem a visão.


Table				Heatmap			
	Α	В	C		Α	В	C
Category 1	15%	22%	42%	Category 1	15%	22%	42%
Category 2	40%	36%	20%	Category 2	40%	36%	20%
Category 3	35%	17%	34%	Category 3		17%	34%
Category 4	30%	29%	26%	Category 4			
Category 5	55%	30%	58%	Category 5	55%		58%
Category 6	11%	25%	49%	Category 6	11%	25%	49%

FIGURE 2.5 Two views of the same data

Heavy borders			Light borders				Minimal borders				
Group	Metric A	Metric B	Metric C	Group	Metric A	Metric B	Metric C	Group	Metric A	Metric B	Metric (
Group 1	\$X.X	Y%	Z,ZZZ	Group 1	\$X.X	Y%	Z,ZZZ	Group 1	\$X.X	Y%	Z,ZZZ
Group 2	SX.X	Y%	Z,ZZZ	Group 2	\$X.X	Y%	Z,ZZZ	Group 2	\$X.X	Y%	Z,ZZZ
Group 3	SX.X	Y%	Z,ZZZ	Group 3	\$X.X	Y%	Z,ZZZ	Group 3	\$X.X	Y%	Z,ZZZ
Group 4	\$X.X	Y%	Z,ZZZ	Group 4	\$X.X	Y%	Z,ZZZ	Group 4	\$X.X	Y%	Z,ZZZ
Group 5	\$X.X	Y%	Z,ZZZ	Group 5	\$X.X	Y%	Z,ZZZ	Group 5	\$X.X	Y%	Z,ZZZ

FIGURE 2.4 Table borders

Escolhas sobre o design dos gráficos






FIGURE 4.4 Preattentive attributes


Source: Adapted from Stephen Few's Show Me the Numbers, 2004.

Recursos para destacar atributos.

Caminho do foco do leitor


Escolhas sobre o design dos gráficos






Barras do gráfico

Escala do gráfico



ColorBrewer Blues Heat Viridis

Categórico



Quantitativo



Destaque

Amigável a daltônicos





Círculo cromático

Que informação devemos apresentar?

Quem: a quem iremos

falar


O que: ideia que queremos passar

Como: escolha da


informação apresentada



Visualizando quantidades



Visualizando distribuições



Visualizando proporções




Visualizando proporções








Relações entre duas variáveis



Dado geoespacial










Visualizando incerteza



Séries temporais







Figure 14.1: Daily closing values of the Dow Jones Industrial Average for the year 2009. Data source: Yahoo! Finance



Faces de Chernoff








Diagrama de Sankey




Gráfico de Florence Nightingale (Coxcomb Plot)

Atenção às legendas







Importância da escolha do gráfico





FIGURE 0.2 Example 1 (before): showing data

Ticket volume over time



Data source: XYZ Dashboard, as of 12/31/2014 | A detailed analysis on tickets processed per person and time to resolve issues was undertaken to inform this request and can be provided if needed.

Importância da escolha do gráfico




FIGURE 0.6 Example 3 (before): showing data

To be competitive, we recommend introducing our product below the \$223 average price point in the \$150-\$200 range




FIGURE 0.7 Example 3 (after): storytelling with data

Importância da escolha do gráfico

Survey Results




FIGURE 0.4 Example 2 (before): showing data

Pilot program was a success How do you feel about science? BEFORE program, the majority of children felt just OK about science. 40% AFTER program, more children were Kind of

interested

Based on survey of 100 students conducted before and after pilot program (100% response rate on both surveys).

Kind of

Excited

FIGURE 0.5 Example 2 (after): storytelling with data

OK

Bored


Not great

interested & Excited about

science:

Gráfico de pizza

Evite o gráfico de pizza. Se fizer questão, saiba que não passa muita informação. Use então a regra do Pacman.



75%

Muito mais impactante que um gráfico de pizza.

Scatterplot

Cost per mile by miles driven




FIGURE 2.6 Scatterplot

Cost per mile by miles driven





FIGURE 2.7 Modified scatterplot

Slopegraph

Employee feedback over time



Employee feedback over time




FIGURE 2.11 Modified slopegraph

Elimine a poluição visual




FIGURE 3.24 Before-and-after

Foco direcionado




FIGURE 4.11 First, push everything to the background




FIGURE 4.14 Data labels used sparingly help draw attention

Acréscimo de informações no gráfico





FIGURE 4.14 Data labels used sparingly help draw attention

Please approve the hire of 2 FTEs

to backfill those who quit in the past year

Ticket volume over time



Data source: XYZ Dashboard, as of 12/31/2014 | A detailed analysis on tickets processed per person and time to resolve issues was undertaken to inform this request and can be provided if needed.

FIGURE 5.10 Add action title and annotation

Exemplo



Product C

2011

Product D

Product E

2014

To be competitive, we recommend introducing our product below the \$223 average price point in the \$150-\$200 range







FIGURE 8.20 Before-and-after


Product B

Product A

Extra: Visualização informação através de grafos




Grafo do aplicativo Obsidian



Grafo de Conhecimento

Extra: Análise de sobrevivência



Ferramentas

- Python
 - Seaborn
 - Matplotlib
 - Plotly
 - geoplotlib
 - o Folium
- R
 - Gráficos mais específicos de estatística, como QQ plot
 - Gráficos interativos

Obs: olhar sempre a documentação.

Ferramentas de DashBoard

- Python
- Data Studio (Google)
- PowerBI
- Tableau
- InDesign
- Slides (Google)

Inspiração

- Pinterest
- Behance (Adobe)
- Data Studio Report Gallery

Bibliografia

Fundamentals of Data Visualization - Claus O. Wilke

Exploratory Data Analysis for Feature Selection in Machine Learning - Google Cloud

https://datavizcatalogue.com/

Storytelling with data - Cole Nussbaumer Knaflic

dúvidas?